

TA đọc nhằm bao nhiêu học viên đang gặp 1 vấn đề

Bot báo cáo **4 gạch đầu dòng riêng** cho việc thực chất chỉ **3 học viên** hỏi cùng 1 chủ đề trong 79 phút — đếm 1 người (D6014) hỏi 2 lần thành 2 vấn đề khác nhau.

- **Job executor:** TA/Learning Coach đọc bản tin cuối ngày do bot "Trợ lý" tự đăng trên Discord.
- **Core JTBD:** Khi đọc bản tin cuối ngày, TA muốn biết đúng số học viên đang gặp mỗi vấn đề, để quyết định vấn đề nào cần ưu tiên trả lời trước.

Khảo sát trên toàn bộ 4 bản tin thật: **15/16 bullet (93,75%)** có thể gộp lại thành cụm nhỏ hơn — bot hiện tại đang phình to lượng thông tin TA phải đọc một cách bất hợp lý.

Nguồn: data/discord-pack/k4_daily_reports.md · k4_messages.csv

4 ứng viên đã cân nhắc — chọn ứng viên có bằng chứng mạnh nhất

Ứng viên	Bao nhiêu người	Khả thi trong sự kiện	Quyết định
A. Gộp cụm câu hỏi trùng ý	35 học viên duy nhất (60 tin chứa deadline/nộp/hạn)	Cao — 1 lời gọi AI + hậu kiểm bằng code	CHỌN
B. Trả lời logistics chỉ từ nguồn chính thức	Cùng nhóm 35 người	Trung bình — cần xây kho nguồn riêng	Loại — trùng hướng track B1
C. Phát hiện học viên "stuck", chủ động hỗ trợ	Khó ước lượng bằng mining	Thấp — rủi ro an toàn cao	Loại — cấm tự động nhấn học viên
D. Tóm tắt riêng câu hỏi điểm danh	22 học viên duy nhất	Cao nhưng phạm vi hẹp	Loại — quy mô nhỏ hơn A

Ứng viên A ảnh hưởng **35 / 779 (~4,5%)** tin không-phải-bot trong 3 ngày pack — nhóm người bị ảnh hưởng lớn nhất đo được.

Một TA · một bản tin cuối ngày · một quyết định AI

Một TA đọc bản tin cuối ngày · AI gom câu hỏi trùng ý thành một dòng đếm theo **số học viên duy nhất** kèm link nguồn · TA biết đúng có bao nhiêu người thực sự đang vướng một vấn đề.

Automation: Conditional

- Tự gộp khi chắc chắn cùng chủ đề
- Không tự gộp khi mơ hồ — tách riêng, gắn cờ "cần TA xác nhận"
- Lý do: gộp lố 2 deadline khác nhau khiến TA trả lời sai — sai thì đắt

Demo trực tiếp — 2 case

- **Case chuẩn** Cụm "nộp Lab2 muộn" gộp đúng 3 học viên, mức ưu tiên ● Cao
- **Case chỗ khó** Model từng lỡ đưa câu hỏi cá nhân vào cụm công khai — bị chặn bởi **lưới an toàn thứ 2 bằng code**, độc lập với lời hứa của AI trong prompt

Ba lượt đo — số xấu vẫn ghi nhận trung thực

0	Lưới an toàn (code)	10/10 PASS
1	AI thật, thử tay	5/7 (~71%)
2	Golden set, tự động	5/5 PASS

Quality bar đã chốt: đạt khi **≥80%** case không vi phạm 4 lớp lỗi, và **100%** case lớp ③ (riêng tư) phải đạt.

Failure đáng kể nhất: case lớp ③ (câu hỏi cá nhân) FAIL ở lượt đo đầu vì model không tuân prompt 100% — đã vá bằng lưới an toàn code độc lập, đo lại: **PASS**.

Đánh giá qua golden set thật trên 766 tin nhắn

"Case lớp ③ ban đầu FAIL thật — model đưa câu hỏi cá nhân vào cụm công khai dù đã dẫn trong prompt. Sau khi vá lưới an toàn: PASS."

Nguồn: eval/run_log_2.md — chạy trên toàn bộ 766 tin thật từ data/discord-pack

- **5/5 case tự động kiểm được: PASS** — bao gồm đúng việc tách 3 loại "deadline" khác nhau không gộp nhầm, và chặn đúng câu hỏi cá nhân khỏi cụm công khai
- 1 case FAIL thật ở lượt đầu (lớp ③) → phân tích nguyên nhân, vá bằng lưới an toàn thứ 2, đo lại xác nhận đã sửa
- 13 case còn lại trong golden set (case thường, case hiếm) đang được chấm tay bằng cách đọc trực tiếp output AI

Ưu tiên tiếp theo — trở thẳng về failure đã thấy

- Build nút "tách cụm" cho TA tự sửa khi AI gộp sai (nguyên tắc G9 — hiện chưa build)
- Bắt lỗi rõ ràng khi gọi API thất bại (2/7 lần ở lượt 1 do lỗi gọi API chưa rõ nguyên nhân)
- Mở rộng golden set lên 30+ case bằng promptfoo

Bài học lớn nhất: **không thể chỉ tin AI tuân theo instruction ở lớp lỗi nghiêm trọng nhất** (riêng tư) — phải có lưới an toàn bằng code độc lập. Và phải tự kiểm tra lại chính bộ đo: lần đầu vá xong vẫn báo FAIL vì quên nối lưới an toàn vào script test.